CoCoA: Фреймворк минимального байесовского риска для квантования неопределённости в больших языковых моделях

Roman Vashurin Maiya Goloburda Preslav Nakov Albina Ilina Artem Shelmanov
Aleksandr Rubashevskii Maxim Panov

Mohamed bin Zayed University of Artificial Intelligence (MBZUAI)
{Roman.Vashurin, Maiya.Goloburda, Maxim.Panov}@mbzuai.ac.ae

План выступления

1. Введение и мотивация
2. Теоретические основы
3. Метод CoCoA
4. Экспериментальная установка
5. Результаты экспериментов
6. Абляционные исследования
7. Дополнительные исследования
8. Заключение

Проблема: квантование неопределённости в БЯМ

Два основных семейства подходов

1. **На основе информации**: оценка уверенности по вероятностям токенов
2. **На основе согласованности**: оценка семантического согласия при повторном сэмплировании

Ключевая проблема

Современные гибридные методы не демонстрируют стабильного превосходства над базовыми подходами

Вызов

Обеспечение надёжности выходов БЯМ критически важно в сценариях с высокими ставками

Проблема: ограничение информации уровня последовательности

Пример несогласованных вероятностей

Вопрос: *«Тибальт — персонаж какой из пьес Шекспира?»*

Сэмплированные ответы:

- «romeo and juliet» 0,667
- «romeo & juliet» 0,045
- «romeo and juliet.» 0,030

Ключевой инсайт

Семантически идентичные ответы получают разные вероятности, что демонстрирует ограничение подходов на основе информации

Декодирование с минимальным байесовским риском

Фреймворк MBR

$$\mathrm{y}_* = \arg\min_{\mathrm{y}\in\mathcal{Y}} R(\mathrm{y} \mid \mathrm{x}), \quad R(\mathrm{y} \mid \mathrm{x}) = \mathbb{E}_{\mathrm{y}'\sim p(\mathrm{y}|\mathrm{x})}\left[r(\mathrm{y}, \mathrm{y}')\right]$$

- **Стандартный выбор**: $r(\mathrm{y}, \mathrm{y}') \propto -s(\mathrm{y}, \mathrm{y}')$
- **Неопределённость на основе MBR**: $U_{\mathrm{MBR}}(\mathrm{y}_* \mid \mathrm{x}) = R(\mathrm{y}_* \mid \mathrm{x})$
- Обеспечивает теоретическую основу для объединения уверенности и согласованности
- Bayes Risk (Байесовский риск): Это ожидаемые потери при принятии решения в условиях неопределенности, усредненные по всем возможным исходам согласно их вероятностям.

Сравнение существующих подходов

На основе информации

- Sequence Probability, Perplexity, Mean Token Entropy
- Анализируют распределения вероятностей токенов

Ограничения

- Один сэмпл
- Игнорируют семантическую вариабельность
- Зависят от калибровки модели

На основе согласованности

- Semantic Entropy, Self-consistency
- Анализируют семантические отношения между сэмплами

Ограничения

- Отбрасывают информацию о вероятностях
- Вычислительно затратны
- Игнорируют уверенность модели

CoCoA: Объединение уверенности и согласованности

Комбинированная функция риска

$$r(\mathrm{y}, \mathrm{y}' \mid \mathrm{x}) = u(\mathrm{y} \mid \mathrm{x}) \cdot (1 - s(\mathrm{y}, \mathrm{y}'))$$

где $s(\mathrm{y}, \mathrm{y}') \in [0, 1]$ — семантическая схожесть, $u(\mathrm{y} \mid \mathrm{x}) \geq 0$ — неопределённость на основе модели

Мера неопределённости CoCoA

$$U_{\mathrm{CoCoA}}(\mathrm{y}_* \mid \mathrm{x}) = u(\mathrm{y}_* \mid \mathrm{x}) \cdot \mathbb{E}_{\mathrm{y}' \sim p(\mathrm{y} \mid \mathrm{x})}[1 - s(\mathrm{y}_*, \mathrm{y}')]$$

Эмпирическая оценка

$$\widehat{U}_{\mathrm{CoCoA}}(\mathrm{y}_* \mid \mathrm{x}) = u(\mathrm{y}_* \mid \mathrm{x}) \cdot \frac{1}{M} \sum_{i=1}^{M} (1 - s_{*i})$$

Принцип работы CoCoA

1. LLM генерирует ответ y_*
2. Генерация M альтернативных ответов через сэмплирование
3. Оценка семантической схожести s_{*i} между y_* и альтернативами
4. Вычисление уверенности модели $u(\mathrm{y}_* \mid \mathrm{x})$
5. Комбинация: $U_{\mathrm{CoCoA}} = u(\mathrm{y}_* \mid \mathrm{x}) \cdot \frac{1}{M} \sum (1 - s_{*i})$

Ключевой принцип

- **Высокая схожесть + высокая уверенность** $\rightarrow$ низкая неопределённость
- **Низкая схожесть** или **низкая уверенность** $\rightarrow$ высокая неопределённость

CoCoA Light: Эффективная аппроксимация

Проблема

Полная версия требует множественных сэмплов $\rightarrow$ значительные вычислительные затраты

Решение

$$\widehat{U}^L_{\text{CoCoA}}(y_* \mid x) = u(y_* \mid x) \cdot \widehat{U}^L_{\text{cons}}(y_* \mid x)$$

где $\widehat{U}^L_{\text{cons}}$ аппроксимируется обучаемой функцией $\widehat{g}$

Llama 3.1 8B	Mistral 7B	Falcon 3 7B
16-й слой	**16-й слой**	**14-й слой**

Стратегии декодирования и выборки

Четыре подхода к выбору выхода

1. **Greedy декодирование**: выбор кандидата с топ-1 вероятностью на каждом шаге
2. **Случайная выборка**: случайный выход среди сэмплов от повторного промптинга
3. **Наиболее вероятный сэмпл**: выход с наивысшей вероятностью от модели
4. **MBR сэмпл**: выход с наивысшей средней согласованностью

Ключевое наблюдение

Выбор случайного сэмпла приводит к значительному падению качества на нескольких датасетах, наиболее заметно на GSM8k

Три setup для оценки UQ

1. **Greedy декодирование**
2. **Стохастическое сэмплирование** с фокусом на наиболее вероятном сэмпле
3. **MBR декодирование**

Базовые метрики качества по стратегиям выборки

Sample	Metric	Greedy	Random Sample	Most Probable Sample	MBR Sample
			Falcon7b-Base		
CoQA	Align Score	0.793	0.706	0.783	0.793
GSM8k	Accuracy	0.776	0.313	0.205	0.419
MMLU	Accuracy	0.715	0.638	0.715	0.699
TriviaQA	Align Score	0.557	0.473	0.568	0.559
WMT14FrEn	Comet	0.867	0.833	0.857	0.855
WMT19DeEn	Comet	0.846	0.807	0.826	0.828
XSUM	Align Score	0.842	0.734	0.782	0.801
			Llama8b-Base		
CoQA	Align Score	0.756	0.671	0.743	0.766
GSM8k	Accuracy	0.548	0.234	0.261	0.346
MMLU	Accuracy	0.570	0.368	0.577	0.469
TriviaQA	Align Score	0.686	0.625	0.687	0.699
WMT14FrEn	Comet	0.863	0.819	0.852	0.844
WMT19DeEn	Comet	0.870	0.816	0.854	0.845
XSUM	Align Score	0.848	0.608	0.825	0.703
			Mistral7b-Base		
CoQA	Align Score	0.793	0.695	0.777	0.790
GSM8k	Accuracy	0.382	0.169	0.190	0.259
MMLU	Accuracy	0.632	0.552	0.632	0.612
TriviaQA	Align Score	0.743	0.655	0.750	0.739
WMT14FrEn	Comet	0.863	0.812	0.830	0.841
WMT19DeEn	Comet	0.864	0.805	0.836	0.837
XSUM	Align Score	0.803	0.578	0.775	0.665

Таблица 2: Базовые метрики качества для моделей при различном выборе оцениваемой последовательности.

Датасеты и модели

Датасеты

QA: TriviaQA, CoQA, MMLU, GSM8k

Перевод: WMT14 FR-EN, WMT19 DE-EN

Суммаризация: XSUM

Модели

- LLaMA 3.1 8B
- Mistral 7B
- Falcon 3 7B

Важно: модели с открытыми весами обеспечивают доступ к вероятностям токенов

Параметры генерации

Температура $T = 1.0$, top-k $= 50$, top-p $= 1.0$

Метрики оценки

Prediction Rejection Ratio (PRR)

$$PRR = \frac{\mathrm{AUC}_{\mathrm{unc}} - \mathrm{AUC}_{\mathrm{rnd}}}{\mathrm{AUC}_{\mathrm{oracle}} - \mathrm{AUC}_{\mathrm{rnd}}}$$

- **Oracle**: оптимальная стратегия отклонения
- **UQ**: оцениваемый метод
- **Random**: базовая линия
- Вычисляется до **50% порога отклонения**

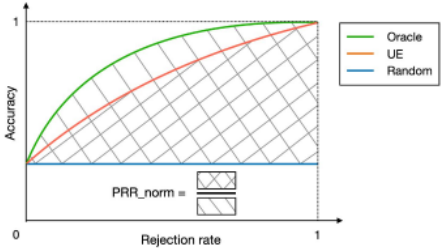

Рисунок 3: Кривая PRR

Основные результаты

Metric	Llama8b-Base			Mistral7b-Base			Falcon7b-Base		
	QA	NMT	SUM	QA	NMT	SUM	QA	NMT	SUM
MCSE	0.310	0.323	0.033	0.389	0.304	0.007	0.414	0.317	0.159
MCNSE	0.309	0.393	0.022	0.384	0.410	0.009	0.405	0.422	0.108
Semantic Entropy	0.356	0.343	0.033	0.423	0.327	0.008	0.439	0.348	0.164
DegMat	0.406	0.302	0.081	0.423	0.305	0.137	0.483	0.353	0.201
EigValLaplacian	0.375	0.238	0.079	0.391	0.267	0.132	0.459	0.312	0.201
SAR	0.414	0.455	0.077	0.462	0.435	0.094	0.481	0.458	0.144
P(True)	-0.064	0.042	0.058	-0.029	0.075	0.179	0.118	0.155	-0.159
Consistency	0.437	0.421	0.024	0.471	0.392	0.051	0.494	0.416	0.226
Consistency Light	0.390	0.458	-0.022	0.444	0.387	-0.006	0.427	0.476	0.232
SP	0.409	0.399	0.328	0.475	0.383	0.287	0.475	0.356	0.201
CoCoA$_{SP}$	0.451 ↑	**0.519** ↑	0.378 ↑	**0.509** ↑	**0.497** ↑	**0.330** ↑	0.511 ↑	0.505 ↑	**0.257** ↑
CoCoA$_{SP}$ Light	0.449 ↑	0.502 ↑	0.358 ↑	0.503 ↑	0.480 ↑	0.309 ↑	0.492 ↑	0.514 ↑	0.242 ↑
PPL	0.381	0.386	0.369	0.424	0.427	0.204	0.456	0.450	0.155
CoCoA$_{PPL}$	**0.454** ↑	0.481 ↑	**0.387** ↑	0.494 ↑	0.472 ↑	0.286 ↑	0.523 ↑	0.508 ↑	0.229 ↑
CoCoA$_{PPL}$ Light	0.445 ↑	0.487 ↑	0.382 ↑	0.479 ↑	0.480 ↑	0.260 ↑	0.512 ↑	0.528 ↑	0.234 ↑
MTE	0.353	0.382	0.357	0.417	0.438	0.182	0.456	0.473	0.152
CoCoA$_{MTE}$	0.447 ↑	0.478 ↑	0.380 ↑	0.492 ↑	0.469 ↑	0.288 ↑	**0.527** ↑	0.508 ↑	0.228 ↑
CoCoA$_{MTE}$ Light	0.428 ↑	0.494 ↑	0.372 ↑	0.475 ↑	0.482 ↑	0.254 ↑	0.507 ↑	**0.533** ↑	0.234 ↑

Выводы из экспериментов

1. **Методы CoCoA** — лучшие по всем задачам и моделям
2. **Стабильное превосходство** над Semantic Entropy, SAR и всеми базовыми методами
3. **Объединение подходов работает**: уверенность на уровне токенов + семантическая согласованность
4. **CoCoA Light** — практичная альтернатива с меньшими вычислительными затратами

Главный результат

Предложенный фреймворк CoCoA **надёжно улучшает квантование неопределённости** в БЯМ

Абляционные исследования

Функция схожести

- Cross-encoder: надёжный выбор по умолчанию
- AlignScore: лучше для суммаризации
- NLI: эффективна для длинных ответов QA

Формулировки

- **Мультипликативная** > аддитивная
- Фокус на оцениваемой последовательности > усреднение по парам
- Логарифмическая vs вероятностная: схожие результаты

Главные выводы

- Предложенная формулировка хорошо разработана
- Мультипликативная форма критична для учёта взаимодействий
- Cross-encoder служит надёжным выбором по умолчанию

Дополнительные методы и метрики

Дополнительные методы UQ

- **Semantic Entropy**: кластеризация в семантически однородные группы
- **SentenceSAR**: усиление релевантных предложений
- **SAR**: объединяет SentenceSAR и TokenSAR
- **P(True)**: модель явно выражает уверенность (True/False)

Альтернативные метрики

- **AUROC**: результаты для QA датасетов (Приложение G)
- **GPT-as-a-judge**: оценка корректности ответов
- **MetricX**: для задач машинного перевода

Детальные результаты

Приложение E: расширенные PRR scores для каждого датасета отдельно (Таблицы 11, 12, 13)

Вычислительные ресурсы

Вычислительный бюджет исследования

- **12 вычислительных узлов**, каждый с 4×A100 40GB GPU
- **Общий бюджет**: около 400 GPU-дней
- **В среднем**: 16 GPU-дней на каждую комбинацию модели и датасета

Что включено

- Генерация всех выходов модели
- Извлечение hidden states
- Вычисление всех метрик неопределённости
- Обучение CoCoA Light вспомогательных моделей

CoCoA Light преимущество

- Только одна генерация при инференсе
- Значительно снижает затраты в production
- Сохраняет качество полной версии

Ограничения метода

Зависимость от задачи и домена

- Эффективность варьируется между моделями, задачами, доменами
- Открытые задачи: ожидаются разнообразные выходы
- Точное рассуждение: чувствительно к тонким ошибкам

Вычислительная стоимость

- Генерация множества сэмплов — затратна
- Эксперименты используют относительно небольшие наборы
- CoCoA Light решает эту проблему

Метрики качества

Оценка производительности зависит от метрик качества (COMET, Accuracy), которые могут не учитывать все нюансы

Заключение и будущая работа

Вклад работы

- **CoCoA** — унифицированный подход, интегрирующий уверенность и согласованность
- Основан на **декодировании с минимальным байесовским риском**
- **Превосходит** современные методы квантования неопределённости для QA, SUM, MT
- **CoCoA Light** — эффективная альтернатива для промышленного применения

Направления будущих исследований

- **Адаптивные стратегии сэмплирования** для эффективного захвата пространства выходов модели
- **Функции для конкретных доменов** (генерация кода, рассуждения здравого смысла)
- **Уточнение метрик качества** для глубокого рассуждения, фактологической точности

Спасибо за внимание!

Вопросы?